YASSINE CHAOUCH

Étudiant en M2 DataScale | Stage de fin d'études (6 mois) recherché | Data • IA • Développement logiciel
92360 Meudon-La-Forêt | (+33) 06 51 96 88 06 | yassinemuedon@gmail.com

FORMATION

Université Paris-Saclay - Master DataScale
2024 - 2027

Université de Versailles Saint-Quentin-en-Yvelines - Licence Informatique
2019 - 2024

PROJETS ACADÉMIQUES

Qualité de données
2026

- Pipeline de contrôle et nettoyage de données hétérogènes : détection des doublons, incohérences, valeurs manquantes, anomalies et règles métier.
- Automatisation des contrôles, du monitoring et des alertes pour suivre la fiabilité des données. Outils : SQL, Python, Pandas, Spark, Airflow, dbt, Power BI / Tableau.

Mistral 7B
2026

- Expérimentation du modèle pour des cas d'usage NLP et IA générative (génération, résumé, Q&A), avec prompt engineering et benchmarking.
- Intégration dans des pipelines applicatifs et exploration de solutions RAG / fine-tuning. Outils : Python, Hugging Face, LangChain, Ollama, FastAPI, Docker.

Machine Learning – prédiction de propriétés moléculaires
2025

- Pipeline ML (prétraitement SMILES, extraction d'embeddings, régression supervisée) et comparaison de ChemBERTa, SMILES-BERT et DeepChem.
- Optimisation avec Optuna et évaluation (R^2, RMSE) pour la prédiction du pIC50.

Application Web – Partage de récits de voyage
2025

- Plateforme collaborative React 18 / Vite avec recherche, filtres avancés et calendrier interactif.
- React Router, Tailwind CSS et JWT ; favoris, notifications en temps réel et partage d'images.

COMPÉTENCES

Data Science & ML Python, scikit-learn, pandas, NumPy, PyTorch, Optuna, Jupyter
Backend & Frontend Node.js, Express.js, React 18, MongoDB, PostgreSQL, Oracle
Outils Git, GitHub, Docker, Linux, Power BI, Apache Spark

LANGUES & INTÉRÊTS

- Français (Maternelle), Anglais (Courant), Arabe (Maternelle), Espagnol (Professionnel)
- Voyage, Photographie, Football

FORMATION & UE PERTINENTES

Licence Informatique — UVSQ

LSIN516 — Machine Learning : concepts et algorithmes

LSIN513 — Bases de données

LSIN408 — Introduction aux bases de données

Algorithmique : fondements, approfondissements et techniques avancées

LSMA430N — Probabilités et statistiques élémentaires

Master DataScale — Paris-Saclay

Apprentissage statistique et machine learning

Deep learning et intelligence artificielle

Big data et systèmes distribués

Bases de données avancées

Data mining et analyse de données

Optimisation et méthodes numériques

PROJETS — DÉTAILS TECHNIQUES

Qualité des données

Pipeline avec SQL, Spark, Airflow et dbt : contrôles automatisés, monitoring et alertes. Python, Pandas et Power BI pour la fiabilité.

Mistral 7B

Réimplémentation PyTorch : GQA, SWA, RoPE, RMSNorm, SwiGLU, cache KV et benchmarking.

TER DataScale — langage chimique

ChemBERTa, ChemGPT, SMILES-BERT, RDKit et embeddings moléculaires. Régression pIC50, Optuna et suivi Weights & Biases.

Tripline — application web

Next.js, React, TypeScript, Tailwind CSS et JWT. Recherche, filtres, calendrier, favoris et notifications en temps réel.